Çok Modlu OSINT Konum Tahmin Sistemleri ve GeoAI: "GeoEngine" Mimarisi İçin Kapsamlı Literatür ve Teknoloji Analizi

Açık Kaynak İstihbaratı (OSINT) ve dijital adli bilişim disiplinlerinde, meta verisi (EXIF/GPS) silinmiş veya kasıtlı olarak manipüle edilmiş görsel materyallerin coğrafi kökeninin tespit edilmesi, tarihsel olarak analistlerin bilişsel kapasitelerine ve manuel doğrulama süreçlerine bağımlı, yavaş ve hata payı yüksek bir analitik alan olmuştur. Geleneksel yöntemler; görüntü içerisindeki dağınık görsel ipuçlarının, örneğin gölge açıları, bitki örtüsü türleri, mimari yapılar, topografik silüetler ve otonom metinlerin zihinsel olarak birleştirilmesini ve bu verilerin Coğrafi Bilgi Sistemleri (CBS/GIS) veritabanları ile manuel olarak eşleştirilmesini gerektirmektedir. Ancak, kayıp şahıs vakaları, siber olaylara müdahale, failin coğrafi izinin sürülmesi ve dezenformasyon kampanyalarının çürütülmesi gibi zamana karşı yarışılan kritik senaryolarda, bu analitik süreçlerin tamamen veya yarı otonom olarak gerçekleştirilmesi hayati bir zorunluluk haline gelmiştir.

Son yıllarda Yapay Zeka (AI), Bilgisayarlı Görü (Computer Vision) ve Büyük Çok Modlu Modellerin (Large Multimodal Models - LMM) kesişiminde ortaya çıkan GeoAI (Geospatial Artificial Intelligence) teknolojileri, bu soruna ölçeklenebilir ve yüksek doğruluklu çözümler sunmaktadır. Tümüyle otonom çalışan veya karar destek mekanizması olarak "döngüde insan" (human-in-the-loop) paradigmasını benimseyen yeni nesil mimariler, yalnızca küresel ölçekte nokta tabanlı koordinat tahmini yapmakla kalmamakta; aynı zamanda analiz sonuçlarını anlamlı "olasılık poligonları" (probability polygons) halinde haritalandırarak analistlerin kullanımına sunmaktadır.

Bu araştırma raporu, görsel verilerden otonom konum tahmini yapabilen çok modlu bir OSINT karar destek motorunun (örneğin tasarım aşamasındaki "GeoEngine" projesinin) inşasında temel alınabilecek akademik literatürü, son teknoloji (State-of-the-Art - SOTA) algoritmaları, sistem mimarilerini ve alt bileşen yeteneklerini derinlemesine incelemektedir. Raporda, ajan tabanlı akıl yürütme sistemlerinden, gölge ve topografya analizlerine, bitki örtüsü sınıflandırma ağlarından mekansal veri görselleştirme kütüphanelerine kadar geniş bir yelpazede teknolojik fizibilite analizi sunulmaktadır.

Görüntü Tabanlı Coğrafi Konumlandırmada Paradigma Değişimi ve Temel Modeller

Görüntü tabanlı coğrafi konumlandırma (image geolocalization), görsel bir girdinin dünya üzerindeki karşılığı olan kesin enlem ve boylam koordinatlarına dönüştürülmesi problemi olarak tanımlanmaktadır. Erken dönem yaklaşımlar, bu problemi salt bir "görüntü geri çağırma" (image retrieval) sorunu olarak ele almış ve devasa CBS veri tabanlarındaki coğrafi etiketli referans fotoğraflar ile piksel tabanlı, el yapımı öznitelik (SIFT/SURF) eşleştirmeleri yapmaya çalışmıştır. Ancak bu yöntemler, Eyfel Kulesi veya Kolezyum gibi ayırt edici yapıların (landmarks) bulunmadığı durumlarda veya referans veri tabanının kapsamadığı ücra coğrafyalarda ciddi genelleme sorunları yaşayarak başarısızlığa uğramıştır.

Güncel paradigma, problemi salt bir görsel eşleştirme sorunu olmaktan çıkarıp, çok modlu bağlamsal akıl yürütme (multimodal contextual reasoning) ve makine öğrenmesi tabanlı mekansal sınıflandırma (spatial classification) problemine dönüştürmüştür. Yeni nesil Çok Modlu Büyük Dil Modelleri (MLLM/VLM), mimari stilleri, bitki örtüsünü, yol düzenlerini ve iklimsel koşulları semantik olarak algılayarak, açık uçlu mantıksal çıkarımlar yapabilmektedir. Bu değişim, algoritmaların tıpkı uzman bir OSINT analisti gibi çalışmasını, bölgesel farklılıkları tümdengelim yoluyla elemesini ve olasılık uzayını logaritmik olarak daraltmasını sağlamıştır.

PIGEON ve PIGEOTTO: Semantik Hücreler ve Zıtlayıcı Öğrenme

Küresel ölçekte konum tahmini yapabilen sistemlerin kalbinde, coğrafi verilerle eğitilmiş temel (foundation) modeller yer almaktadır. Bu alanda literatürü sarsan en önemli gelişmelerden biri, PIGEON (Predicting Image Geolocations) ve onun açık kaynak varyantı olan PIGEOTTO mimarileridir. OpenAI'nin CLIP (Contrastive Language-Image Pretraining) Vision Transformer (ViT) omurgasını kullanan bu modeller, yapay zekanın gezegen ölçeğinde konum tahmini yapabilme kapasitesini benzeri görülmemiş bir seviyeye taşımıştır. PIGEON modelinin başarısının ardında yatan temel faktörler; çoklu görev zıtlayıcı ön eğitim (multi-task contrastive pretraining) mekanizması, semantik coğrafi hücreler (semantic geocells) algoritması ve rafine edilmiş bir kayıp (loss) fonksiyonudur.

Geleneksel uzamsal sınıflandırma sistemleri, S2 geometri kütüphaneleri gibi araçlar kullanarak dünyayı birbirine eşit matematiksel karelere (grid) bölerken, bu yaklaşım okyanusların ortasındaki boş hücreler ile yoğun metropollerdeki veri yığılmaları arasında ciddi bir dengesizlik yaratmaktadır. PIGEON ise bunun yerine, açık kaynaklı sınır verilerini (örneğin idari seviye 2 sınırları - admin 2 boundaries) kullanarak dünyayı "semantik olarak anlamlı" çokgenlere (polygons) göre organik olarak bölmektedir. Algoritma, komşu yönetimsel hücreleri, her bir hücrede en az otuz eğitim verisi (minimum training samples) kalacak şekilde akıllıca birleştirmekte; ancak bu birleştirme işlemini asla uluslararası ülke sınırlarını (ISO kodlarını) ihlal edecek şekilde yapmamaktadır. Bu sayede model, "Paris'in yoğun kentsel alanı" ile "Paris'in kırsal banliyöleri" arasındaki anlamsal ve mimari farkı koruyarak çok daha granüler bir tahminde bulunabilmektedir.

Modelin çıkarım (inference) aşaması, çok katmanlı bir iyileştirme hattından oluşur. Görüntünün vektörel temsili (embedding) hesaplandıktan sonra, en yüksek olasılıklı K adet (Top-K) coğrafi hücre tespit edilmektedir. Daha sonra, bu hücreler içerisindeki konum kümeleri üzerinde OPTICS kümeleme algoritması çalıştırılarak, çıkarım yapılan görüntünün vektörü ile hedef kümeler arasındaki L2 mesafesi (Euclidean distance) minimize edilmektedir. Eğitim sırasında, tahmin edilen coğrafi hücrelerin gerçek lokasyona olan mesafesini coğrafi olarak doğru bir şekilde cezalandırmak için Haversine kayıp fonksiyonu (Haversine loss) kullanılmaktadır. Haversine formülü, küresel bir yüzey üzerindeki iki nokta arasındaki büyük daire mesafesini hesapladığı için, modelin coğrafi uzaydaki fiziksel mesafeleri organik olarak öğrenmesi sağlanmaktadır. PIGEON, Google Street View verilerinden oluşan GeoGuessr veri setiyle eğitilirken; PIGEOTTO versiyonu Flickr ve Wikipedia gibi çok daha geniş, gürültülü ve yapılandırılmamış açık kaynak verileriyle eğitilerek açık dünya koşullarında önceki SOTA modellere kıyasla ülke seviyesinde %38.8'e varan devasa bir performans artışı sağlamıştır.

GeoCLIP: Dünyayı Sürekli Bir Fonksiyon Olarak Modellemek

PIGEON'un sınıflandırma (grid classification) tabanlı kısıtlamalarını aşmak üzere tasarlanmış bir diğer devrimsel mimari ise GeoCLIP'tir. Izgara tabanlı (grid-based) yöntemler, bir görüntünün konumu sınıf merkezinden önemli ölçüde saptığında genellikle yanlış yerelleştirmelere yol açmaktadır. GeoCLIP, dünyayı kesikli hücreler yerine "sürekli bir fonksiyon" (continuous function) olarak modelleyerek bu sınırlamayı ortadan kaldırmaktadır. Model, görüntüleri doğrudan GPS koordinatlarıyla eşleştirerek (Image-to-GPS retrieval) CLIP'ten ilham alan, ancak uzamsal boyuta uyarlanmış bir zıtlayıcı öğrenme çerçevesi sunmaktadır.

GeoCLIP mimarisinin temelinde, coğrafi koordinatları yüksek boyutlu öznitelik vektörlerine dönüştürmek için Rastgele Fourier Özellikleri (Random Fourier Features) kullanan özel bir konum kodlayıcı (location encoder) yer almaktadır. Bu kodlayıcı, Eşit Alan Projeksiyonu (Equal Earth Projection) kullanarak GPS bozulmalarını (distortion) hafifletmekte ve çok katmanlı algılayıcılarla (MLP) birleştirilerek dünyanın farklı çözünürlüklerdeki (yüksek frekanslı konumsal kodlama) hiyerarşik temsillerini yakalamaktadır.

Sistemin en büyük avantajı, sınıflandırma tabanlı modellere kıyasla sadece %20'lik bir eğitim verisiyle bile rekabetçi sonuçlar elde edebilmesidir. Ayrıca, önceden eğitilmiş bu konum kodlayıcının ürettiği 512 boyutlu GPS yerleştirmeleri (embeddings), başka GeoAI görevlerinde (örneğin arazi sınıflandırması, hava durumu tahmini, mahsul verimi analizi) doğrudan bir girdi olarak kullanılabilmektedir. Model, görüntü ile coğrafya arasında kurduğu bu zengin anlamsal uzay sayesinde, sadece bir görselden koordinat bulmakla kalmayıp, metin tabanlı coğrafi sorgulara da (örneğin "tropikal iklim, yüksek dağlık alan, katedral") cevap verebilecek kavramsal bir yorumlanabilirlik (Concept-Aware Alignment) sunmaktadır.

Aşağıdaki tablo, bu temel GeoAI mimarilerinin OSINT tabanlı bir motor geliştirilirken dikkate alınması gereken karakteristik özelliklerini özetlemektedir:

Model / Mimari Özelliği	**Temel Yaklaşım / Çekirdek**	**Kayıp (Loss) ve Optimizasyon**	**Veri Temsili ve Koordinat Üretimi**	**İşlem Maliyeti ve Genelleme**
PIGEON / PIGEOTTO	Semantik Hücre (Geocell) + CLIP ViT	Haversine + Contrastive Loss	K-Means / OPTICS Kümeleme, Kesikli Sınıflandırma	Yüksek (Özel ön eğitim gerektirir), Sınıf içi yüksek genelleme.
GeoCLIP	Sürekli Fonksiyon (Continuous Function)	Image-to-GPS Contrastive Loss	Random Fourier Features, Sürekli Koordinat Uzayı	Düşük/Orta (MLP konum kodlayıcı), Çok düşük veriyle yüksek performans.
StreetCLIP	Etki Alanına Özgü Ön Eğitim	Zero-Shot Contrastive Matching	Ülke/Bölge Etiketleriyle Sentetik	Düşük (Kullanıma hazır),

Model / Mimari Özelliği	Temel Yaklaşım / Çekirdek	Kayıp (Loss) ve Optimizasyon	Veri Temsili ve Koordinat Üretimi	İşlem Maliyeti ve Genelleme
	(Domain-specific)		Açıklamalar (Captions)	Kentsel/Kırsal peyzajda anında çıkarım.

Ajan Tabanlı (Agentic) Mimariler ve Coğrafi Akıl Yürütme Döngüleri

Derin öğrenme modelleri (CNN'ler veya ViT'ler) görsel verileri vektör uzayına taşıyarak istatistiksel olarak iyi bir ön tahmin yapsalar da, OSINT disiplini doğası gereği mantıksal bir hipotez kurma ve ampirik doğrulama (hypothesis-verification) döngüsü gerektirir. Standart makine öğrenmesi modelleri, tüm dünya coğrafyasını, kültürünü ve mimarisini statik parametrik belleklerinde tutmaya çalıştıkları için, açık dünya koşullarında veya dinamik bilgi gerektiren durumlarda "olgusal halüsinasyonlara" (factual hallucinations) eğilimlidirler. Bu epistemolojik sorunu çözmek için geliştirilen ajan tabanlı (agentic) sistemler, Büyük Dil Modellerini (LLM) birer "bilişsel merkez" (cognitive hub) olarak konumlandırmakta ve mekansal akıl yürütmeyi araç kullanımı ile desteklemektedir.

LocationAgent ve RER Mimarisi

LocationAgent, yapay zeka tabanlı konum tahmini literatüründe akıl yürütme stratejileri ile kanıt doğrulama süreçlerini birbirinden açıkça ayrıştıran (explicit decoupling) öncü bir hiyerarşik ajandır. Model, konumlandırma işlemini tek adımlık bir tahmin olmaktan çıkarıp, tıpkı insan bir araştırmacı gibi Dışa Çıkarımsal Kısıt Sağlama (Abductive Constraint Satisfaction) sürecine dönüştürür. Bu süreci yönetmek için özel olarak tasarlanmış RER (Reasoner-Executor-Recorder) mimarisi kullanılmaktadır.

RER mimarisinin bileşenleri şunlardır:

1. **Reasoner (Akıl Yürütücü):** Sistemin bilişsel çekirdeğidir. Görüntüdeki en belirgin ipucundan başlayarak hangi doğrultuda ilerlenmesi gerektiğine ve hangi alt modülün (aracın) çağrılacağına karar verir. Hiyerarşik bir planlama yaparak tümdengelim stratejisini kurgular.
2. **Executor (Uygulayıcı):** Bilişsel uzay ile dış dünya (gerçek harita verileri, arama motorları) arasındaki etkileşim köprüsüdür. Dört farklı uzmanlaşmış "eylem uzayı" (action space) modülünden oluşur:
   - *Çevresel Modül (Environmental Module):* Dağ sıraları, bitki örtüsü tipleri, toprak rengi ve iklim belirteçleri gibi makro-coğrafi özellikleri analiz ederek aday bölgeyi kıta veya ülke seviyesinde devasa oranlarda daraltır (örneğin tropikal vs. karasal iklim).
   - *Altyapı Modülü (Infrastructure Module):* Mimari stiller, bina yapım malzemeleri, trafik yönü, yol çizgisi standartları, elektrik direği tipleri ve kamu tesisleri gibi altyapı özelliklerini analiz ederek şehrin sosyo-ekonomik düzeyini ve olası bölgesini belirler.
   - *Semantik Sembol Modülü (Semantic Symbol Module):* Tabela, mağaza isimleri, sokak tabelaları, posta kodları ve plaka formatları üzerinde Optik Karakter Tanıma (OCR) çalıştırarak, bu kültürel ipuçlarını idari bölünmelere veya doğrudan sokak seviyesindeki İlgi Çekici Noktalara (POI) haritalar.

- *Görüntü Eşleştirme Modülü (Image Matching Module):* Belirlenen spesifik yapıların (örneğin bir köprü, anıt veya özgün bir gökdelen) devasa veri tabanlarında veya tersine görsel arama (reverse image search) motorlarında görsel benzerlik aramalarını yürütür.

3. **Recorder (Kaydedici):** Çok adımlı (multi-step) karmaşık akıl yürütme süreçlerinde, ajanın daha önce denediği, kanıt bulduğu veya elediği mantıksal yolları bir durum takipçisi (state tracking) olarak kaydeder. Bu modül, bağlam sıkıştırması (context compression) yaparak ajanın bir döngüye girmesini veya "akıl yürütme sürüklenmesi" (reasoning drift) yaşamasını engeller.

NAVIG, GeoChain ve GeoLocSFT: Doğal Dil Rehberliği ve CoT

Ajan mimarilerinin yanı sıra, modellerin mantıksal kapasitesini artırmak için Doğal Dil İşleme (NLP) yeteneklerinin mekansal analize entegre edildiği çerçeveler de mevcuttur. NAVIG (Natural Language-guided Analysis with Vision Language Models), görüntü konumlandırma sürecine tümdengelimsel bir doğal dil zinciri (Chain-of-Thought - CoT) ekleyen yenilikçi bir çerçevedir. Araştırmacılar, GeoGuessr oyunundaki dünya çapındaki uzman oyuncuların oynanış kayıtlarını ve sesli düşünme süreçlerini (transcripts) metne dökerek "NaviClues" adında yüksek kaliteli bir veri seti oluşturmuştur. Bu veri setiyle eğitilen görsel dil modelleri, görüntüyü alt parçalara (crop) bölmeyi, dış bilgi kaynaklarına özel arama sorguları üretmeyi ve elde ettiği veriler ışığında bir insan uzman gibi akıl yürütmeyi öğrenmektedir. NAVIG, 1000'den az eğitim örneğiyle bile önceki SOTA modellere kıyasla ortalama mesafe hatasında %14 oranında bir azalma sağlamıştır.

Benzer bir mantıkla oluşturulan **GeoChain** veri seti, 1.46 milyon Mapillary sokak seviyesi görüntüsünü 21 adımlı bir Düşünce Zinciri (CoT) soru dizisiyle eşleştirmektedir. Bu yapı, modeli kaba görsel özelliklerden (örneğin "burada dağlar var") ince taneli yerelleştirmeye (örneğin "bu dağların silüeti ve tabeladaki dil burasının İsviçre Alpleri olduğunu gösteriyor") doğru yönlendirmektedir.

Devasa modellerin (GPT-4 vb.) API maliyetlerinden ve kapalı kaynak kısıtlamalarından kaçınmak için geliştirilen **GeoLocSFT** çerçevesi ise, Gemma 3 veya Qwen2 gibi daha küçük ancak açık ağırlıklı (open-weights) modellerin kullanılmasını önermektedir. Bu yaklaşımda, görüntüdeki "mikro özelliklerin" (micro-features) (örneğin spesifik bir endemik bitki türü, hafif farklılık gösteren bir çatı stili veya spesifik bir yol çizgisi paterni) belirlenmesi sağlanmaktadır. En önemlisi, modelden sadece doğru konumu bulması değil, elde ettiği kanıtların neden *diğer* görsel olarak benzer coğrafyalara ait olamayacağının (explicit reasoning for disambiguation) açıklamasını sağlayan "coğrafi başlıklar" (geo-captions) üretmesi istenir. Retrieval-Augmented Generation (RAG) teknikleriyle entegre edilen bu sistemler, analiz edilen görüntüye sadece benzer olan (pozitif) konum ipuçlarını değil, aynı zamanda benzemeyen (negatif) konum örneklerini de (dissimilar images geolocation information) bağlama dahil ederek modelin yanılma payını minimuma indirmektedir.

Aşağıdaki tablo, OSINT tabanlı bir GeoEngine inşası için değerlendirilebilecek ajan tabanlı ve RAG odaklı mimarileri karşılaştırmaktadır:

Mimari / Çerçeve Adı	Temel Akıl Yürütme Mekanizması	Doğrulama ve Kanıt Toplama (RAG / Tool Use)	Eğitim Stratejisi ve Veri Seti Kapsamı
LocationAgent	RER (Reasoner-Executor-Recorder)	4 Harici Modül (Çevre, Altyapı, Sembol, Görsel Arama)	CCL-Bench (Çin şehir konumları), Sıfır-Atışlı (Zero-shot) Genelleme
NAVIG	NLP Destekli Düşünce Zinciri (CoT)	Görüntü Kırpma (Cropping) ve Harici Bilgi Sorgulama	NaviClues (GeoGuessr uzman transkriptleri), <1000 örnekle yüksek başarı
GeoLocSFT	Mikro-Özellik Eleyicisi (Disambiguation)	RAG Destekli Pozitif/Negatif Konum Karşılaştırması	MR40k, Yüksek kaliteli "Geo-captions" ile Supervised Fine-Tuning (SFT)
GeoLocator	Rol Tanımlı LMM (GPT-4) Entegrasyonu	Kod Yorumlayıcı (Image Enhancement), API Entegrasyonu	Turistik ve Gündelik OSINT veri setleri, Çoklu açı analizi (Multi-angle)

Görüntü İçi Fiziksel İpuçlarının Çıkarımı ve Algoritmik Analizi

Bütünleşik bir OSINT karar destek motorunun (GeoEngine) çevresel verileri derinlemesine anlamlandırabilmesi için salt dil modellerine güvenmesi yetersizdir; özel alt yetenek modüllerine (computer vision algoritmaları ve matematiksel formüller) ihtiyacı vardır. Görüntü içerisindeki izole bileşenler tek başlarına sınırlı bir anlam ifade ederken, uygun algoritmalarla bağlama oturtulduklarında devasa bir istihbarat değerine dönüşürler. Bir OSINT çerçevesinde bağlam (context), ön plan (foreground), arka plan (background) ve harita işaretleri (map markings) sistematik olarak incelenmelidir.

1. Gölge Analizi ve Astronomik Konum Tahmini (Chronolocation & Geolocation)

Görsellerdeki gölgeler, fotoğrafın çekildiği coğrafi konum ve o anki kesin zaman dilimi (chronolocation) hakkında mutlak astronomik veriler sunan en güçlü deterministik araçlardır. Geleneksel OSINT'te Bellingcat gibi organizasyonlar tarafından manuel yürütülen bu süreç, astronomik matematik formüllerinin bilgisayarlı görü algoritmalarıyla birleştirilmesiyle tamamen otonom hale getirilebilmektedir.

Temel astronomik mantık, güneşin gökyüzündeki konumunu belirleyen iki ana açıya dayanır: Güneşin ufuktan yüksekliğini belirten yükselti açısı (elevation/altitude angle, θ) ve pusula yönünü belirten azimut açısı. Bir nesnenin bilinen yüksekliği (h) ile zemine düşen gölgesinin uzunluğu (l) arasındaki ilişki basit bir trigonometrik fonksiyona dayanır: $\tan(\theta) = h / l$.

Bellingcat tarafından açık kaynaklı olarak geliştirilen **ShadowFinder** aracı, bu matematiği kullanarak devrimsel bir yaklaşım sunmaktadır. Araca, bir nesnenin gölge uzunluğu, referans nesnenin yüksekliği ve fotoğrafın çekildiği kesin UTC zaman bilgisi girildiğinde, sistem güneşin o anki yükselti açısını hesaplar. Daha sonra, yeryüzünde o spesifik tarih ve saatte tam olarak bu açıyı verebilecek tüm coğrafi noktaları hesaplayarak, dünya haritası üzerinde bir "ışık halkası" (bright circle / probability polygon) olarak çizer. Giriş verilerindeki olası piksel ölçüm hatalarını ve lens distorsiyonlarını tolere etmek için bu ana poligonun etrafına mor renkle ifade edilen %20'lik hata bantları (error bands) eklenerek arama uzayı güvenli bir marjinde tutulur. Benzer şekilde, SunCalc gibi araçlar, zaman parametresi bilindiğinde gölge yönüne (azimut) bakarak fotoğrafçının hangi yöne (kuzey/güney vb.) baktığını kesin olarak doğrulamak için kullanılır.

Yapay zeka tabanlı otonom bir GeoEngine inşası için gölgenin insan müdahalesi olmadan, otomatik olarak tespit edilmesi (shadow detection) gerekir. Literatürde, uydu ve hava fotoğraflarında piksel tabanlı bulut ve gölge tespiti yapan SPARCS (Spatial Procedures for Automated Removal of Cloud and Shadow) gibi sinir ağı yaklaşımları mevcuttur. Karasal (terrestrial / ground-level) görüntülerde ise, gölgelerin hareketli nesnelerden veya koyu renkli materyallerden ayırt edilmesi karmaşık bir problemdir. Bu ayrımı yapmak için Hessenberg dekompozisyonu (HD) ve Temel Bileşenler Analizi (PCA) kombinasyonları, ayrıca gölgenin sert (umbra) veya yumuşak (penumbra) yapısını inceleyen yerel sinyal-gürültü oranı (SNR) filtreleri kullanılmaktadır. Hava fotoğraflarında (aerial images) gölgenin tespit edilmesi için atmosferik saçılımdan (atmospheric scattering) kaynaklı olarak derin gölge bölgelerinde kısa dalga boylarının (mavi ve mor spektrum) daha belirgin olması özelliğinden yararlanılarak spektrum oranı (spectrum ratio properties) analizleri uygulanır.

Coğrafi gölge çıkarımının (urban shadow analysis) sentetik olarak otomatize edilmesinde Python kütüphaneleri büyük rol oynar. **pybdshadow** ve **Street Shadow** gibi araçlar, LiDAR ve 3D bina DTM (Digital Terrain Model) verileri üzerinden sanal bir ışık kaynağı (nokta ışık veya hesaplanmış güneş ışığı vektörü) kullanarak şehir ölçeğinde gölge projeksiyonları (shadow maps) üretmektedir. Üretilen bu 2.5D gölge haritaları ile incelenen görüntüdeki gölge paternleri bilgisayarlı görü algoritmaları ile eşleştirilerek yüksek kesinlikli yer tespiti sağlanabilir. Özellikle ağırlıklı grafikler (weighted graphs) ve Dijkstra algoritması kullanılarak gölge projeksiyonlarına dayalı kentsel mekansal yönlendirme algoritmaları dahi oluşturulabilmektedir.

2. Bitki Örtüsü ve Mimari Stil Sınıflandırması

İklim kuşakları, fitososyolojik bitki toplulukları (phytosociology) ve yerel mimari formasyonlar, OSINT araştırmacıları için o coğrafyanın doğal birer barkodu işlevini görür. Bu bağlamda, bitki örtüsü ve mimari stili milisaniyeler içinde sınıflandırmak için evrişimli sinir ağları (CNN) ve çok modlu derin öğrenme (Multimodal Deep Learning) sistemleri "GeoEngine"in altyapısına entegre edilmelidir.

Peyzaj ve bitki sınıflandırmasında, YOLOv8 algoritması gibi tek aşamalı (single-stage) uçtan uca mimariler (Backbone-Neck-Head) kullanılarak yaprak döken ağaçlar, yaprak dökmeyen ağaçlar ve çalı formları birbirinden yüksek hassasiyetle ayırt edilebilmektedir. ABD ulusal bitki örtüsü sınıflandırma standardı olan USNVC gibi hiyerarşik veri setleri ve taksonomik sözlükler, yapay zeka sistemlerinin bitkilerin bölgesel dağılımını (endemik mi, istilacı mı, hangi iklim kuşağına ait) tespit etmesinde ontolojik bir veri tabanı sağlar. Amazon gibi tropikal bölgelerde ince taneli vejetasyon haritalaması için Landsat ve SPOT HRG uydu görüntülerinden spektral imzalar ile birlikte Gri Seviye Eş-Oluşum Matrisi (GLCM) gibi mekansal doku (texture) ölçümleri kullanılarak CNN'lerin sınıflandırma doğruluğu artırılmaktadır. Bu sınıflandırmaların OSINT modellerine entegrasyonunda, VRS-Seg görevi (çok modlu ve çok zamanlı uzaktan algılama görüntülerinde hedef vejetasyon alanlarının segmantasyonu) ve Vejetasyon Bilgi Grafikleri (Vegetation Knowledge Graph - VKG) gibi semantik bağlantı araçları büyük bir potansiyel taşımaktadır. CRAUNet (Concatenated Residual Attention UNet) gibi modeller ise artıkıl modüller (residual modules) ve dikkat mekanizmaları (attention mechanism) kullanarak kentsel yeşil alanların zengin bağlamsal bilgisini çıkarabilmektedir.

Mimari yapı ve kentsel formasyon analizlerinde, bir bölgedeki binaların çatı yapıları, kullanılan yapı materyalleri (örneğin Doğu Karadeniz'deki ahşap-taş işçiliği veya Akdeniz'deki beyaz sıvalı yapılar), sokakların dizilimi ve hatta ön bahçe/arka bahçe (frontyard/backyard) oranları dahi o coğrafyanın sosyo-ekonomik ve kültürel yapısını saniyeler içinde ele verir. CBS3-LandGen gibi modeller, ConvNeXt mimarisini kullanarak karmaşık kentsel görüntü verisini işlerken, BART modeli ile görsel-metinsel bilgi füzyonu (evidence fusion) yaparak bölgesel mimari analizleri doğal dil açıklamalarıyla destekler. Daha hücresel bir analiz için DALES (Dayton Annotated Laser Earth Scan) gibi devasa nokta bulutu (point cloud) veri setleri kullanılarak 3D LiDAR taramalarından binaların, bitki örtüsünün ve yolların eş zamanlı anlamsal bölütlemesi (semantic segmentation) sağlanır; ardından bu vektörel veriler Raster görüntülerle çakıştırılarak konum olasılıkları topolojik olarak hesaplanır.

3. Topografik Eşleştirme ve Dağ Silüeti Analizi

Ufuk çizgisinde yer alan sıradağlar, tepeler ve doğal yükseltiler, değişmeyen, mevsimsel şartlardan (kısmen) etkilenmeyen ve yüzlerce kilometre öteden dahi görülebilen mutlak referans noktalarıdır. OSINT bağlamında dağ silüetlerini kullanarak fotoğrafın konumunu bulmak, geleneksel olarak saatler süren harita taramalarını gerektirirken, günümüzde 3D topografik veri tabanlarıyla 2 boyutlu fotoğrafların eşleştirilmesi (superimposing) algoritmalarına dayanmaktadır.

Bu alanda öne çıkan en güçlü mekanizmalardan biri, Bellingcat bünyesindeki POPSI (PeakVisor Open Source Investigative) projesi kapsamında geliştirilen yaklaşımlardır. **PeakVisor** algoritması ve benzeri sistemler, yeryüzünün yüksek çözünürlüklü 3 boyutlu Dijital Yükseklik Modelleri'ni (DEM/DTM - Digital Elevation Models) ve SRTM (Shuttle Radar Topography Mission) verilerini kullanarak, dünya üzerindeki *herhangi* bir koordinattan bakıldığında görülecek panoramik manzarayı near-photographic (fotoğrafik kaliteye yakın) kalitede render edebilmektedir.

Model, otonom bir "GeoEngine" sisteminden gelen 6 Serbestlik Dereceli (6-DoF) bir giriş matrisini işler: Enlem, boylam, rakım, yunuslama (pitch), sapma (yaw) ve yuvarlanma (roll) açıları ile birlikte kameranın Yatay Görüş Açısı (HFOV - Horizontal Field of View). Sistemin

çekirdek mekanizması (PhotoFit), şüpheli 2 boyutlu görüntüdeki (I_q) dağ silüeti kenarlarını (edge detection) çıkararak, render edilen 3 boyutlu modelin silüeti ile piksel ve eğri eşleştirme (curve matching) yöntemleriyle üst üste oturtmaktır (superimposing). Derinlik ve ufuk çizgisine olan mesafenin hesaplanması, paralaks (parallax) kaymalarının düzeltilmesi ve farklı görüş alanlarının (FOV) fokal uzunluklarla olan optik ilişkisinin analiz edilmesi, sistemin sadece fotoğrafın çekildiği coğrafi konumu değil, aynı zamanda kameranın durduğu milimetrelik noktayı ve hatta fotoğrafın hangi lens milimetresi ile çekildiğini de devasa bir kesinlikle (confirmation and elimination strategy) kanıtlamasını sağlar.

Mekansal Olasılık Poligonları ve Veri Görselleştirme Teknikleri

Geleneksel GPS veya EXIF verisi doğrudan tek bir koordinat noktası verirken, "GeoEngine" gibi çok modlu bir karar destek motorunun nihai çıktısı, kullanıcıya kesin bir (x,y) koordinatı sunmaktan ziyade, hesaplanan onlarca farklı coğrafi ipucunun (gölge, bitki, mimari, dil) örtüştüğü alanları "Mekansal Olasılık Poligonları" (Spatial Probability Polygons) olarak ifade etmektir. Bu yaklaşım, analiste yapay zekanın "kara kutu" (black box) mantığını dayatmak yerine, harita üzerinde logaritmik olarak daraltılmış bir arama uzayı (search space) ve güven aralığı (confidence interval) sunar.

Semantik Bölümleme (Semantic Partitioning - SemPa) ve Olasılık Modelleri

Derin öğrenme modellerinin dünya haritası üzerinde oluşturduğu tahmin dağılımlarını rastgele matematiksel karelere bölmek, gerçek dünya topolojisini yansıtmaz. Bunun yerine, "Semantik Bölümleme" (SemPa - Semantic Partitioning) mimarisi kullanılır. Açık Sokak Haritası (OpenStreetMap - OSM) veya GADM gibi idari sınır veritabanlarından elde edilen vektörel çoklu poligonlar (multi-polygons) kullanılarak makine öğrenmesi sınıflandırma probleminin uzayı organik olarak tanımlanır.

Modelin çıkarım anında her bir anlamsal sınıf (yani yeryüzündeki bir ilçe, mahalle, göl veya milli park poligonu) için hesapladığı Softmax skorları, o poligonun gerçek konum olma olasılık değerini belirler. Analiste sunulan web arayüzünde, hedef bölge bu gerçek dünya sınırlarına (cadde kıvrımları, nehir yatakları, ülke sınırları) riayet edecek şekilde bir ısı haritası (heatmap) olarak boyanır.

Çoklu modüllerden gelen ipuçlarının birleştirilmesinde (örneğin gölge analizinden çıkan Kıtalararası aday çemberi ile altyapı analizinden çıkan kentsel doku poligonunun üst üste bindirilmesi) Olasılıksal Mekansal Veri Modeli (Probabilistic Spatial Data Model - PSDM) adı verilen bir matematiksel yapı kullanılır. İki veya daha fazla olasılık poligonunun (A ve B poligonları) mekansal olarak kesiştiği (spatial join / geometric intersection) bölgelerdeki yeni olasılık skoru, poligonların sınır belirsizlikleri ve bağıl hata payları hesaba katılarak yeniden normalize edilir. Çok büyük coğrafi alanları analiz ederken, poligon veri kümeleri içerisinde rastgele uzamsal örnekleme (spatial random sampling) yapılması gereken durumlarda, karmaşık "delikli poligon" (polygon with holes) yapıları öncelikle Ear Clipping gibi algoritmalarla Delaunay üçgenlemesi (triangulation) yöntemiyle daha basit üçgenlere bölünür; ardından alanla orantılı olarak rastgele veri noktaları üretilir.

Python Tabanlı Mekansal Kütüphaneler ve Arka Plan (Backend) Mimarisi

Bir "GeoEngine" sisteminin altyapısını kodlarken, Python ekosistemindeki mekansal veri kütüphaneleri işin omurgasını oluşturur. Olasılık poligonlarının harita üzerinde görselleştirilmesi ve Raster/Vektör verilerin anında analiz edilmesi için şu araçlar kritik öneme sahiptir:

Python Kütüphanesi	**Temel İşlev ve Mekansal Görev (OSINT / GeoAI Bağlamı)**
GeoPandas	Vektör verilerin (nokta, çizgi, poligon) manipülasyonu. İdari sınırların veri çerçevesi (DataFrame) olarak tutulması ve uzamsal kesişimlerin (spatial joins) hesaplanması.
Shapely	Kartezyen düzlemde geometrik operasyonlar. Ray Casting algoritmaları, point-in-polygon (nokta poligonda mı?) testleri ve poligonlar arası mesafe ölçümleri.
Rasterio / xarray	Uydu görüntüsü ve dijital yükseklik modeli (DEM) gibi Raster (piksel tabanlı) verilerin okunması. Matrisler üzerinden mekansal alt kümeler (spatial subsetting) çıkarma.
Folium / ipyleaflet	Leaflet.js tabanlı interaktif web haritalarının Python içinden render edilmesi. Isı haritalarının (heatmaps) ve olasılık poligonlarının arayüze basılması.
OSMnx	OpenStreetMap verilerinin indirilerek yol ağları (network) ve kentsel topolojinin graf (graph) teorisi üzerinden matematiksel olarak modellenmesi.
anygeom	OSINT araçlarının test edilmesi için farklı projeksiyonlarda (örn. UTM, Web Mercator) rastgele test poligonları ve geometri kümeleri üretilmesi.

Otonom sistemlerin performansını optimize etmek ve yüksek eşzamanlı sorguları yönetmek amacıyla, veri görselleştirmede Ramer–Douglas–Peucker çizgi basitleştirme (line simplification) algoritmaları (örn. GeoRAP) kullanılarak, büyük hacimli mekansal verilerin doğruluğundan ödün verilmeden tarayıcıdaki render yükünün logaritmik olarak azaltılması sağlanmaktadır.

Etik Boyutlar, Coğrafi Gizlilik (Geo-Privacy) ve Güvenlik Tehditleri

Teknolojinin ulaştığı bu muazzam analitik kapasite, aynı zamanda "Coğrafi Gizlilik" (Geo-Privacy) kavramını derinden sarsan bir siber güvenlik tehdidi doğurmuştur. Geleneksel olarak, bir görüntünün konumunu gizlemek için EXIF meta verilerini silmek yeterli kabul edilirken; LMM'ler, VLM'ler ve "GeoEngine" gibi karar destek sistemleri, doğrudan görüntünün piksellerinden konum çıkarsayarak bu korumayı fiilen geçersiz kılmıştır.

GPT-4, Claude veya özel eğitilmiş PIGEON/GeoCLIP gibi modeller, sıradan insanların tatil fotoğraflarında arka planda kalan bir elektrik direğinin tipinden, bir ağacın yaprak yapısından veya zemin kaplamasından yola çıkarak kişinin ev adresini, iş yerini veya bulunduğu sokağı 100 metreden daha az bir hata payıyla (de-anonymization) tespit edebilmektedir. Akademik çalışmalarda incelenen "GeoLocator" (GPT-4 tabanlı konum çıkarım ajanı) deneylerinde, herhangi bir metin veya açık coğrafi etiket içermeyen gündelik sosyal medya fotoğraflarının konumlarının dahi 100 milin altında bir hata payıyla, çoğunlukla doğrudan sokak seviyesinde tespit edilebildiği kanıtlanmıştır.

Bu durum, özellikle gazeteciler, aktivistler, askeri personel ve siber zorbalık mağdurları için ciddi bir gözetim (surveillance) riski oluşturur. Ayrıca, Generative Adversarial Networks (GAN) ve yapay zeka tarafından üretilen (AI-generated) deepfake görseller, OSINT araştırmacılarını kasten yanlış coğrafyalara yönlendirmek için sentetik olarak üretilmiş mimari veya bitki örtüsü detayları içerebilir.

Bu etik ve operasyonel riskleri hafifletmek için, GeoEngine gibi sistemlerin inşasında LIME (Local Interpretable Model-agnostic Explanations) ve SHAP (SHapley Additive exPlanations) gibi Açıklanabilir Yapay Zeka (XAI) tekniklerinin kullanılması zorunludur. Sistem, analiste sadece bir koordinat vermemeli; o koordinata ulaşırken modelin görüntünün tam olarak neresine odaklandığını (Feature Importance / Activation Maps) açıkça göstermeli ve olası halüsinasyonları engellemek için RAG tabanlı harici doğrulama adımlarını (evidence verification) mecburi kılmalıdır. Aksi takdirde otomasyon önyargısı (automation bias), yanlış sivil hedeflerin veya masum insanların işaretlenmesine yol açabilir.

"GeoEngine" Projesi İçin Sentezlenmiş Mimari Tasarım ve Sonuç

Bu raporda derinlemesine incelenen makine öğrenmesi algoritmaları, açık kaynak OSINT platformları ve SOTA literatür bulguları ışığında; planlanan "Çok Modlu OSINT Konum Tahmin ve Karar Destek Motoru" (GeoEngine) projesi, teknik fizibilite ve operasyonel etki açısından son derece güçlü bir akademik ve pratik temele sahiptir. Böylesine devasa bir sistemi sıfırdan monolitik bir ağ olarak eğitmek yerine, en iyi pratiklerin modüler olarak birleştirildiği aşağıdaki ajan tabanlı mimari (Agentic Framework) yaklaşımının benimsenmesi önerilmektedir:

1. **Hiyerarşik Ajan ve Kontrol Katmanının Kurulması (Cognitive Layer):** Sistemin beyni, LocationAgent projesinin kanıtladığı RER (Reasoner-Executor-Recorder) mimarisi üzerine inşa edilmelidir. Büyük model (örneğin açık ağırlıklı Llama 3 veya Qwen-VL tabanlı bir VLM), doğrudan koordinat tahmini yapan statik bir sözlük olarak değil; gelen görseli analiz edip "Hangi alt aracı çalıştırmalıyım?" sorusunu soran bir *Görev Yöneticisi* olarak konumlandırılmalıdır.
2. **Özelleşmiş Yürütücü Alt Modüllerin (Executor Micro-Services) Geliştirilmesi:** Sisteme statik Python modülleri olarak şu yetenekler eklenmelidir:
   - *Gölge ve Zaman Analizi:* Fotoğrafın çekildiği saat biliniyorsa veya tahmin ediliyorsa, nesne/gölge oranından güneş yükseltisini hesaplayan (ShadowFinder/SunCalc mantığı) ve olasılık poligonu çizen matematiksel bir modül.
   - *Topografya ve Silüet Eşleştirme:* Ufukta dağ görünüyorsa, bunu SRTM ve DEM 3D harita verileriyle paralaks düzeltmesi yaparak (PeakVisor API veya benzeri bir algoritma) eşleştiren bir modül.

- *Semantik Nesne ve Çevre Tanıma:* YOLOv8 veya özelleştirilmiş ConvNeXt kullanılarak mimari materyal, bitki iklim kuşağı (USNVC veritabanı ile) ve OCR tabanlı metin tanıma modülü.

3. **Vektör Hizalama ve Bağlamsal Doğrulama (RAG Layer):** Modelin sıfır atışlı (zero-shot) başarısını artırmak için GeoCLIP veya StreetCLIP gibi coğrafi ön eğitime sahip, "görüntüyü doğrudan GPS vektör uzayıyla eşleyebilen" hazır ağırlıklar (pre-trained embeddings) sisteme dahil edilmelidir. GeoLocSFT yaklaşımında olduğu gibi, sisteme benzer olan pozitif harita örneklerinin yanı sıra, modeli yanıltabilecek benzer ama yanlış (negatif) örnekler de RAG (Retrieval-Augmented Generation) mekanizması ile sunularak modelin "neden o konum olamayacağını" (disambiguation) açıklaması sağlanmalıdır.
4. **Mekansal Sentez ve Arayüz Çıktısı (Visualization Layer):** Alt modüllerden toplanan mekansal veriler (gölgenin verdiği enlem çemberi, bitkinin verdiği iklim kuşağı, mimarinin verdiği kıta), PSDM (Olasılıksal Mekansal Veri Modeli) algoritmaları ile Shapely ve GeoPandas kütüphanelerinde geometrik olarak kesiştirilmelidir (spatial intersection). Nihai sonuç, rastgele matematiksel kareler olarak değil; OpenStreetMap üzerinden çekilecek gerçek idari sınırları (Semantik Bölümleme - SemPa) yansıtan, Folium tabanlı interaktif bir ısı haritası (heatmap / probability polygons) şeklinde analistin ekranına basılmalıdır.

Sonuç olarak, bu modüler ajan yaklaşımı ile tasarlanacak bir "GeoEngine" projesi; literatürdeki salt piksel tabanlı eşleştirme (image-retrieval) kısıtlamalarını tamamen kırarak, meta verisi silinmiş görüntülerde dahi, bir OSINT uzmanının saatlerini alacak akıl yürütme ve doğrulama sürecini saniyeler içinde otonom olarak gerçekleştirebilecek bir siber güvenlik ve istihbarat platformuna dönüşecektir. Akademik dünyanın sunduğu açık kaynak kütüphaneleri, GeoAI modelleri ve topolojik matematik, böylesi karmaşık bir karar destek altyapısının başarıyla inşa edilmesi için gereken tüm teorik ve pratik iskeleti fazlasıyla sunmaktadır.